

Sumário

1. Resumo	2
2. Contexto e Motivação	2
2.1 Sobre o mercado cafeeiro brasileiro	2
2.2 Relevância do Porto de Santos	2
2.3 Problema de negócio — planejamento logístico portuário	3
2.4 Objetivo do projeto	3
3. Fontes de Dados	4
3.1 Base de Dados Bruta do MDIC (Comex Stat)	4
3.2 Filtros aplicados na extração	4
3.3 Tabela auxiliar de países (PAIS.csv)	4
3.4 Tabela de NCM — tipos de café	4
3.5 Limitações das fontes	5
4. Estrutura do Projeto	6
4.1 Organização de pastas e arquivos	6
4.2 Descrição de cada componente	6
5. Pipeline de Dados	8
5.1 Coleta dos dados no Comex Stat	8
5.2 Limpeza e tratamento em Python	8
5.3 Problema identificado na coluna Sacas	8
5.4 Solução adotada	8
5.5 Geração do arquivo corrigido para o Power BI	9
5.6 Colunas auxiliares criadas no Power BI	9
6. Modelagem Preditiva	
6.1 Preparação da série temporal	10
6.2 Escolha do modelo SARIMA	10
6.3 Parâmetros e configuração do modelo	11
7. Dashboard Power BI	13
7.1 Importação e relacionamentos entre tabelas	13
7.2 Medidas DAX criadas	13
7.3 Colunas calculadas	13
7.4 Página 1 — Visão geral das exportações	13
7.5 Página 2 — Destinos e tipos de café	14
7.6 Decisões de design e escolha dos visuais	15
8. Tecnologias Utilizadas	16
8.1 Python e bibliotecas	16
8.2 Power BI	16
8.3 GitHub	16
9. Histórico de Atualizações	17
10. Aprendizados	18

1. Resumo

Este projeto desenvolve uma solução de Ciência de Dados para analisar e prever o volume de exportações de café realizadas pelo Porto de Santos, principal ponto de escoamento do café brasileiro. Foram utilizados dados públicos do Comex Stat (MDIC), abrangendo o período de 2016 a 2025, com foco nas exportações embarcadas pelo porto e nos principais tipos de café comercializados.

O trabalho contempla todas as etapas de um projeto de dados: obtenção, limpeza e tratamento das informações em Python, preparação da série temporal, desenvolvimento de um modelo preditivo SARIMA e construção de um dashboard interativo no Power BI para análise dos resultados. Durante o desenvolvimento, também foi solucionado um problema de incompatibilidade na importação dos dados entre Python e Power BI, garantindo a consistência das análises.

O modelo SARIMA foi utilizado para prever o volume mensal de sacas exportadas, explorando o comportamento sazonal das exportações, enquanto o dashboard fornece indicadores e visualizações que apoiam a tomada de decisão por gestores, exportadores e operadores logísticos. Ao final, são discutidos os principais aprendizados obtidos e apresentadas propostas de evolução do projeto, incluindo comparação com outros modelos preditivos, automatização da coleta de dados e incorporação de novas fontes de informação.

2. Contexto e Motivação

2.1 Sobre o mercado cafeeiro brasileiro

O Brasil é o maior produtor e exportador de café do mundo, respondendo por aproximadamente um terço de toda a produção global. O país exporta principalmente duas variedades: o café arábica, cultivado em regiões de altitude como Minas Gerais e São Paulo, reconhecido pela qualidade e suavidade; e o café robusta (conilon), produzido especialmente no Espírito Santo, com maior teor de cafeína e corpo mais intenso.

O setor cafeeiro tem papel estratégico na balança comercial brasileira, movimentando bilhões de dólares anualmente e empregando milhões de pessoas ao longo de toda a cadeia produtiva, desde o cultivo até a exportação.

2.2 Relevância do Porto de Santos

O Porto de Santos, localizado no litoral do estado de São Paulo, é o maior porto da América Latina e o principal escoadouro das exportações brasileiras de café. Identificado pelo código URF 817800 na base de dados do Comex Stat, o porto concentra a maior parte do volume exportado, servindo como ponto de embarque para produtores de diversos estados, principalmente Minas Gerais, São Paulo e Espírito Santo.

A movimentação no porto é diretamente influenciada por fatores como safra agrícola, oscilações no preço internacional do café, demanda dos países compradores e capacidade logística disponível — tornando a análise e previsão desse fluxo um tema de grande relevância para o planejamento portuário e para o setor exportador.

2.3 Problema de negócio — planejamento logístico portuário

O volume de café exportado pelo Porto de Santos apresenta variações sazonais e tendências de longo prazo que impactam diretamente o planejamento de recursos logísticos como disponibilidade de contêineres, espaço em navios, mão de obra portuária e agendamento de operações.

Antecipar com precisão o volume a ser exportado nos meses seguintes permite que operadores portuários, exportadores e agentes logísticos tomem decisões mais assertivas, reduzam custos operacionais e minimizem riscos de gargalos no fluxo de exportação.

2.4 Objetivo do projeto

O objetivo central deste projeto é desenvolver um modelo de previsão do volume de sacas de café exportadas pelo Porto de Santos, utilizando dados históricos públicos do Comex Stat e técnicas de séries temporais.

Paralelamente, foi desenvolvido um dashboard analítico no Power BI como componente complementar ao projeto. A escolha pelo Power BI, em substituição a um notebook de visualização em Python, foi intencional: o dashboard serviu como oportunidade prática para o desenvolvimento de habilidades em Business Intelligence, comunicação visual de dados e construção de painéis voltados à tomada de decisão.

O projeto integra, portanto, duas frentes complementares: a científica, representada pelo modelo preditivo SARIMA; e a analítica, representada pelo dashboard interativo — refletindo o fluxo completo de um projeto de Ciência de Dados aplicado a um problema real.

3. Fontes de Dados

3.1 Base de Dados Bruta do MDIC (Comex Stat)

Os dados utilizados neste projeto são públicos e foram obtidos no portal Comex Stat, mantido pelo Ministério do Desenvolvimento, Indústria, Comércio e Serviços (MDIC). O Comex Stat é o sistema oficial de estatísticas de comércio exterior do Brasil, disponibilizando informações detalhadas sobre exportações e importações brasileiras com cobertura histórica e granularidade mensal. Foram utilizados os dados de exportação do período de 2016 a 2026.

<https://www.gov.br/mdic/pt-br/assuntos/comercio-exterior/estatisticas/base-de-dados-bruta>

3.2 Filtros aplicados na extração

Os arquivos obtidos no portal Comex Stat correspondem à base completa de exportações brasileiras para cada ano analisado. Os filtros utilizados neste projeto **não foram aplicados durante o download**, mas sim na etapa de preparação dos dados, utilizando Python.

Foram mantidos apenas os registros que atendiam aos critérios definidos para o estudo:

Filtro	Valor aplicado
Fluxo	Exportação
Local de embarque (URF)	Porto de Santos — código 817800
NCM — tipos de café	9011110, 9011190, 9011200, 9012100, 9012200, 9019000

3.3 Tabela auxiliar de países (PAIS.csv)

Para traduzir os códigos numéricos de países presentes na coluna CO_PAIS para seus respectivos nomes, foi utilizada a tabela auxiliar oficial disponibilizada pelo próprio MDIC. Essa tabela contém os códigos e nomes dos países em português (NO_PAIS), espanhol (NO_PAIS_ESP) e inglês (NO_PAIS_ING), além dos códigos ISO alfanuméricos.

No dashboard, foi utilizada a coluna NO_PAIS_ING para o visual de mapa, pois o Power BI reconhece melhor os nomes de países em inglês para geolocalização automática.

<https://www.gov.br/mdic/pt-br/assuntos/comercio-exterior/estatisticas/base-de-dados-bruta>

3.4 Tabela de NCM — tipos de café

Os códigos NCM (Nomenclatura Comum do Mercosul) presentes na base identificam o tipo de café exportado. Como a base do Comex Stat armazena apenas o código numérico, foi criada uma tabela auxiliar de descrições para uso no dashboard:

NCM	Descrição	Nome resumido
9011110	Cafê em grão cru (verde) arábica, não torrado, não descafeinado	Arábica cru
9011190	Outros cafês em grão cru, não torrados, não descafeinados (ex: robusta)	Robusta cru
9011200	Cafê não torrado, descafeinado	Descafeinado cru
9012100	Cafê torrado em grão, não descafeinado	Torrado
9012200	Cafê torrado, descafeinado	Torrado descafeinado
9019000	Outras preparações (cascas, películas e sucedâneos)	Outras preparações

A tabela está disponibilizada no drive:

https://drive.google.com/drive/folders/11IZoH2thNgxGIBSkZGCJUBuV9i15_oUk?usp=sharing

3.5 Limitações das fontes

Apesar da riqueza e confiabilidade da base do Comex Stat, algumas limitações foram identificadas:

Ausência de classificação sensorial: a base não distingue tipos de café por qualidade (gourmet, especial, superior, etc), pois essa classificação é definida pela ABIC para o mercado interno e não integra os registros de exportação do MDIC.

Ausência de porto de destino: a base registra o país de destino (CO_PAIS), mas não o porto de desembarque.

Dados de 2026 parciais: a base contém registros até maio de 2026 no momento da extração. O ano de 2026 foi excluído das análises de total anual para evitar distorções, mas está disponível nos dados brutos.

Arquivos originais não versionados: os arquivos brutos do Comex Stat não foram incluídos no repositório GitHub por excederem o limite de tamanho recomendado. O projeto disponibiliza apenas a base tratada (cafe_limpo.csv e cafe_limpo_corrigido.csv). Para reproduzir o projeto do zero, os dados devem ser baixados diretamente no portal do MDIC.

4. Estrutura do Projeto

4.1 Organização de pastas e arquivos

O projeto está organizado no GitHub seguindo uma estrutura modular que separa dados, notebooks, scripts e o dashboard, facilitando a reprodutibilidade e a manutenção:

```
.
├── data
│   ├── raw
│   │   └── .gitkeep
│   └── processed
│       ├── cafe_limpo.csv
│       └── cafe_limpo_corrigido.csv
├── notebooks
│   ├── limpeza.ipynb
│   └── modelagem.ipynb
├── src
│   └── preprocessing.py
├── dashboard
│   ├── dashboard.pbix
│   └── screenshots
├── documentacao_tecnica.pdf
└── README.md
```

4.2 Descrição de cada componente

data/raw: pasta destinada aos arquivos brutos baixados diretamente do Comex Stat. Mantida vazia no repositório (apenas com `.gitkeep`) devido ao tamanho dos arquivos originais.

data/processed: contém as bases já tratadas — `cafe_limpo.csv`, gerada pelo notebook de limpeza, e `cafe_limpo_corrigido.csv`, versão ajustada especificamente para compatibilidade com o Power BI.

notebooks/limpeza.ipynb: responsável por executar o pipeline de tratamento dos dados, utilizando as funções do módulo `preprocessing.py`, além de realizar a criação da coluna de data e gerar a base tratada `cafe_limpo.csv`.

notebooks/modelagem.ipynb: contém a preparação da série temporal e o desenvolvimento do modelo preditivo SARIMA.

src/preprocessing.py: módulo responsável pelas principais etapas de pré-processamento dos dados, incluindo a importação e consolidação das bases anuais, filtragem das exportações de café embarcadas pelo Porto de Santos e conversão do peso líquido (kg) para quantidade de sacas.

dashboard/: contém o arquivo do Power BI (dashboard.pbix) e capturas de tela do painel final.

5. Pipeline de Dados

5.1 Coleta dos dados no Comex Stat

Os dados brutos foram baixados diretamente do portal Comex Stat , e armazenados localmente na pasta data/raw antes do processamento.

5.2 Limpeza e tratamento em Python (limpeza.ipynb)

O tratamento dos dados foi realizado em Python utilizando a biblioteca **Pandas**, sendo dividido entre um módulo de pré-processamento (preprocessing.py) e um notebook responsável pela execução do pipeline (limpeza.ipynb).

As principais etapas foram:

- **Importação e consolidação:** leitura dos arquivos brutos exportados do Comex Stat e união das bases anuais em um único conjunto de dados.
- **Filtragem:** seleção apenas das exportações de café, por meio dos códigos NCM definidos para o projeto, e das operações embarcadas pelo Porto de Santos (URF 817800).
- **Conversão para sacas:** cálculo da quantidade de sacas de 60 kg a partir da coluna KG_LIQUIDO.
- **Tratamento de datas:** criação da coluna Data a partir das colunas CO_ANO e CO_MES, facilitando as análises temporais.
- **Geração da base tratada:** exportação do arquivo cafe_limpo.csv, utilizado como base para a modelagem preditiva.

5.3 Problema identificado na coluna Sacas

Durante a construção do dashboard, foi identificado um problema na importação do arquivo cafe_limpo.csv pelo Power BI. Embora os dados estivessem corretos no ambiente Python, a ferramenta interpretava incorretamente os valores numéricos devido à configuração regional utilizada na leitura do arquivo CSV.

Como consequência, a coluna **Sacas** apresentava valores incompatíveis com a base original, incluindo quantidades extremamente elevadas e, em alguns casos, valores negativos. Foram realizadas tentativas de correção diretamente no Power BI por meio de alterações na importação e nos tipos de dados, porém os resultados permaneceram inconsistentes.

5.4 Solução adotada

Após verificar que a inconsistência ocorria apenas na importação do arquivo pelo Power BI, optou-se por gerar uma versão da base de dados (café_limpo_corrigido.csv) em um formato compatível com a ferramenta. Para isso, foi criada temporariamente uma célula no notebook responsável apenas pela reexportação do arquivo tratado.

```
import pandas as pd

df_bom = pd.read_csv("../data/processed/cafe_limpo.csv")

df_bom.to_csv("cafe_limpo_certo.csv", index=False, sep=";", encoding="utf-8-sig")
```



```
print("Sucesso!")
```

A solução preservou todos os valores calculados durante o pré-processamento, alterando apenas o formato de exportação do arquivo CSV.

5.5 Geração do arquivo corrigido para o Power BI

O arquivo `cafe_limpo_corrigido.csv` foi criado exclusivamente para utilização no Power BI. A base utilizada durante todo o processo de limpeza, análise exploratória e modelagem preditiva permaneceu sendo o arquivo `cafe_limpo.csv`.

Após a geração da versão compatível, a célula utilizada para essa exportação foi removida do notebook, pois sua finalidade era apenas facilitar a integração entre o Python e o Power BI, não fazendo parte do pipeline principal de processamento dos dados.

5.6 Colunas auxiliares criadas no Power BI

Além do tratamento em Python, algumas colunas auxiliares foram criadas diretamente no Power Query do Power BI para viabilizar visualizações específicas:

AnoMes: coluna calculada combinando ano e mês em um único valor numérico utilizada como apoio em cálculos de contagem distinta de períodos.

```
AnoMes = 'cafe_limpo_corrigido'[CO_ANO] * 100 + 'cafe_limpo_corrigido'[CO_MES]
```

NomeMes: coluna com o nome abreviado do mês em português (jan, fev, mar...), gerada com a função `FORMAT(DATE(...), "MMM")` e classificada pela coluna `CO_MES` para exibição em ordem cronológica nos gráficos.

```
NomeMes = FORMAT(DATE(2000, 'cafe_limpo_corrigido'[CO_MES], 1), "MMM")
```

6. Modelagem Preditiva

6.1 Preparação da série temporal

A modelagem foi realizada a partir da base tratada (cafe_limpo.csv), contendo os registros de exportação de café pelo Porto de Santos entre janeiro de 2016 e dezembro de 2025.

Inicialmente, a coluna Data foi convertida para o tipo datetime e utilizada como índice temporal da base. Em seguida, os registros foram agregados em frequência mensal por meio da soma da coluna Sacas, gerando a série temporal utilizada pelo modelo preditivo.

```
df["Data"] = pd.to_datetime(df["Data"])
df = df.set_index("Data")

serie_mensal = df["Sacas"].resample("MS").sum()
```

A série resultante representa o volume total de sacas exportadas em cada mês do período analisado.

Para avaliar a capacidade preditiva do modelo, a série foi dividida em dois conjuntos:

- **Treinamento:** janeiro de 2016 a dezembro de 2024;
- **Teste:** janeiro de 2025 a dezembro de 2025.

Essa divisão permitiu comparar as previsões do modelo com os valores reais observados durante o ano de 2025 antes da geração das previsões futuras.

```
dados_treino = serie_mensal[:"2024-12-31"]
dados_teste = serie_mensal["2025-01-01":"2025-12-31"]
```

Antes da modelagem, também foi realizada uma inspeção visual da série temporal por meio de um gráfico de linhas, permitindo observar o comportamento das exportações ao longo do período estudado.

6.2 Escolha do modelo SARIMA

O modelo **SARIMA (Seasonal AutoRegressive Integrated Moving Average)** foi escolhido por ser amplamente utilizado na previsão de séries temporais que apresentam tendência e sazonalidade.

A exportação de café possui comportamento influenciado pelo calendário agrícola brasileiro, pelos períodos de colheita e pela dinâmica das exportações ao longo do ano, características que tornam um modelo sazonal uma alternativa adequada para este tipo de problema.

Além disso, o SARIMA apresenta vantagens para uma primeira versão do projeto por exigir apenas o histórico da própria série temporal, dispensando variáveis explicativas adicionais. Seu funcionamento também permite interpretar facilmente a influência das observações passadas e dos componentes sazonais sobre as previsões geradas.

6.3 Parâmetros e configuração do modelo

O modelo foi implementado utilizando a classe SARIMAX da biblioteca **statsmodels**.

Foram utilizados os seguintes parâmetros:

Parâmetro	Valor
p	1
d	1
q	1
P	1
D	1
Q	1
s	12 meses

A configuração corresponde ao modelo:

SARIMA(1,1,1)(1,1,1,12)

em que:

- **p** representa a ordem autorregressiva;
- **d** corresponde ao número de diferenciações aplicadas;
- **q** representa a ordem da média móvel;
- **P, D e Q** são os componentes sazonais equivalentes;
- **s = 12** representa a sazonalidade anual dos dados mensais.

Os parâmetros foram definidos manualmente com base em uma configuração inicial compatível com séries temporais mensais que apresentam comportamento sazonal. Não foram empregados métodos automáticos de seleção de hiperparâmetros, como Grid Search ou AutoARIMA, nesta versão do projeto.

Para permitir maior flexibilidade durante o treinamento, foram utilizados os parâmetros:

```
enforce_stationarity=False
```

```
enforce_invertibility=False
```

Essas configurações evitam que o algoritmo imponha restrições rígidas de estacionariedade e invertibilidade durante o ajuste do modelo, facilitando a convergência do processo de otimização.

7. Dashboard Power BI

O dashboard foi desenvolvido como componente complementar ao projeto, com o objetivo de treinar habilidades em Business Intelligence e comunicação visual de dados, conforme descrito na Seção 1.4.

7.1 Importação e relacionamentos entre tabelas

O modelo de dados do Power BI é composto por três tabelas principais, relacionadas entre si:

Tabela	Função	Relacionamento
cafe limpo corrigido	Tabela fato — dados de exportação tratados	Tabela central
PAIS	Tabela auxiliar — nomes de países	CO PAIS → CO PAIS
tabela ncm cafe corrigida	Tabela auxiliar — descrição dos tipos de café	CO NCM → CO NCM

Ambos os relacionamentos foram configurados com cardinalidade muitos-para-um e direção de filtro única, a partir das tabelas auxiliares em direção à tabela fato.

7.2 Medidas DAX criadas

As principais medidas DAX desenvolvidas para o dashboard foram:

```
Total Sacas = SUM('cafe_limpo_corrigido'[Sacas])

Média Anual Sacas = DIVIDE(SUM('cafe_limpo_corrigido'[Sacas]),
DISTINCTCOUNT('cafe_limpo_corrigido'[CO_ANO]))

Média Mensal Sacas = DIVIDE(SUM('cafe_limpo_corrigido'[Sacas]),
DISTINCTCOUNT('cafe_limpo_corrigido'[AnoMes]))

Total Anual Sacas = SUM('cafe_limpo_corrigido'[Sacas])

Preço Médio Saca USD = DIVIDE(SUM('cafe_limpo_corrigido'[VL_FOB]),
SUM('cafe_limpo_corrigido'[Sacas]))

Ano Pico = VAR Resumo = ADDCOLUMNS(VALUES('cafe_limpo_corrigido'[CO_ANO]), "Total",
CALCULATE(SUM('cafe_limpo_corrigido'[Sacas]))) VAR Maximo = MAXX(Resumo, [Total]) VAR
AnoResultado = MINX(FILTER(Resumo, [Total] = Maximo), 'cafe_limpo_corrigido'[CO_ANO])
RETURN FORMAT(AnoResultado, "0")
```

7.3 Colunas calculadas

```
AnoMes = 'cafe_limpo_corrigido'[CO_ANO] * 100 + 'cafe_limpo_corrigido'[CO_MES]

NomeMes = FORMAT(DATE(2000, 'cafe_limpo_corrigido'[CO_MES], 1), "MMM")
```

7.4 Página 1 — Visão geral das exportações

A primeira página do dashboard apresenta uma visão consolidada e executiva, contendo:

Título: "Café exportado pelo porto de Santos – SP", posicionado no cabeçalho.


Cartões KPI: Ano de Pico, Total de Sacas exportadas e Média Anual de Sacas, posicionados à esquerda para leitura imediata.

Gráfico de barras — Média mensal de sacas por mês: com linha de referência de média geral, eixo X ordenado cronologicamente (jan a dez).

Gráfico de barras horizontais — Soma de sacas exportadas por estado: ranqueando os estados brasileiros de origem por volume exportado.

Gráfico de linha — Total anual de sacas: evolução do volume total de 2016 a 2025.

Rodapé: citação da fonte dos dados (MDIC / Comex Stat).



7.5 Página 2 — Destinos e tipos de café

A segunda página aprofunda a análise em duas dimensões adicionais: geografia de destino e tipo de café exportado:


Cartões KPI: Ano de Pico, Total de Sacas exportadas e Média Anual de Sacas, posicionados à esquerda para leitura imediata.

Gráfico de barras — Total de sacas por tipo de café: Evidencia a forte concentração no café arábica cru.

Mapa de bolhas — Total de sacas por país: visual geográfico com o tamanho da bolha proporcional ao volume exportado para cada país de destino, utilizando a coluna NO_PAIS_ING.

Gráfico de barras — Preço médio da saca por tipo de café (USD): comparando o valor agregado por tipo de café, com rótulos de dados ativados.

Treemap — Top 10 maiores compradores: blocos proporcionais ao volume exportado para os dez principais países importadores.



7.6 Decisões de design e escolha dos visuais

Ao longo do desenvolvimento, algumas decisões de design foram tomadas com base em boas práticas de visualização de dados:

Barras horizontais em vez de gráfico de pizza: para a distribuição por estado, optou-se por barras horizontais em vez de pizza, pois o grande número de categorias (mais de 13 estados) tornava fatias pequenas ilegíveis em formato circular.

Mapa de bolhas em vez de mapa coroplético: escolhido por oferecer maior impacto visual e clareza na identificação dos principais mercados compradores.

Classificação personalizada de eixos: colunas como NomeMes foram classificadas manualmente pela coluna numérica correspondente (CO_MES) para garantir ordem cronológica em vez de ordem alfabética.

8. Tecnologias Utilizadas

8.1 Python e bibliotecas

Python: linguagem principal utilizada no desenvolvimento do pipeline de dados, abrangendo o pré-processamento, tratamento dos dados e modelagem preditiva.

Pandas: biblioteca utilizada para leitura, manipulação, filtragem, agregação e exportação dos dados, além da preparação da série temporal.

Statsmodels: utilizada para implementação, treinamento e geração de previsões com o modelo SARIMA.

Matplotlib: empregada na visualização da série temporal e na comparação entre os valores reais e as previsões do modelo.

JupyterLab: ambiente de desenvolvimento utilizado para execução dos notebooks de limpeza, análise e modelagem.

8.2 Power BI

Utilizado para a construção do dashboard interativo, incluindo modelagem de dados (Power Query), criação de medidas e colunas calculadas (DAX) e desenvolvimento de visualizações.

8.3 GitHub

Utilizado para versionamento do código-fonte, documentação (README.md) e disponibilização pública do projeto como parte do portfólio.

<https://github.com/AlbanyST/Exportacao-de-cafe-no-porto-de-Santos>

9. Histórico de Atualizações

Data	Descrição
04/07/2025	Primeira versão completa do projeto publicada no GitHub, contendo pipeline de limpeza de dados, modelo preditivo SARIMA, Power BI e estrutura inicial de documentação (README).
10/07/2025	Atualização do dashboard no Power BI: inclusão da segunda página do dashboard

10. Aprendizados

Este projeto proporcionou experiência prática em diversas etapas do fluxo de trabalho de um projeto de Ciência de Dados:

Limpeza e transformação de dados reais: lidar com inconsistências típicas de bases governamentais, incluindo formatação regional e valores discrepantes.

Preparação de séries temporais: agregação e estruturação de dados históricos para uso em modelos preditivos.

Modelagem preditiva com SARIMA: aplicação de um modelo estatístico clássico para séries sazonais.

Tratamento de incompatibilidades entre ferramentas: identificação e correção de um problema de formatação decimal entre Python/CSV e Power BI, que gerava valores absurdos nos visuais.

Construção de dashboards: domínio de conceitos de Power Query, DAX, relacionamentos entre tabelas e boas práticas de design de visualizações.

Comunicação de resultados: tradução de dados técnicos em visualizações claras e acionáveis para públicos não técnicos, incluindo a incorporação de feedback externo (sugestões do gestor de projetos).